Prediction du Default de Paiement Carte de Credit

Comparaison de methodes classiques et deep learning
sur le dataset UCI Default of Credit Card Clients

Anesti Gospodinov

Master 2 MBFA - Analyse des Risques de Marche

Fevrier 2026

Table des matieres

1. Introduction et contexte

2. Presentation du dataset

3. Analyse exploratoire

4. Pretraitement et feature engineering

5. Methodologie de validation

6. Resultats - Approche classique

7. Resultats - Deep learning et Focal Loss

8. Composante personnalisee : Focal Loss

9. Comparaison et interpretation

10. Analyse critique et limites

11. Conclusion

1. Introduction et contexte

Le risque de credit constitue l'un des enjeux fondamentaux de la gestion bancaire. Anticiper le defaut de paiement d'un client permet d'ajuster les politiques d'octroi de credit, de provisionner les pertes attendues et de respecter les exigences reglementaires (Bale II/III). Ce projet s'inscrit dans cette logique en proposant une approche de classification binaire : predire si un detenteur de carte de credit fera defaut le mois suivant.

L'objectif est double. D'un point de vue methodologique, on compare rigoureusement quatre modeles classiques (Logistic Regression, Random Forest, XGBoost, LightGBM) avec un reseau de neurones PyTorch equipe d'une Focal Loss personnalisee. D'un point de vue pratique, on cherche le meilleur compromis entre detection des defauts (recall) et precision des alertes, dans un contexte ou le cout d'un defaut non detecte est significativement superieur a celui d'un faux positif.

2. Presentation du dataset

Le dataset *Default of Credit Card Clients* (Yeh & Lien, 2009) provient du UCI Machine Learning Repository. Il porte sur 30 000 clients taiwanais observes d'avril a septembre 2005. Chaque observation comporte 23 variables explicatives et une variable cible binaire.

Variable	Description	Type
LIMIT_BAL	Limite de credit accordee (NT$)	Continue
SEX	1 = Homme, 2 = Femme	Categorielle
EDUCATION	1 = Graduate, 2 = Universite, 3 = Lycee, 4 = Autre	Categorielle
MARRIAGE	1 = Marie, 2 = Celibataire, 3 = Autre	Categorielle
AGE	Age du client (annees)	Continue
PAY_0 ... PAY_6	Statut de paiement mensuel (-2 a 8)	Ordinale
BILL_AMT1...6	Montant facture mensuel (NT$)	Continue
PAY_AMT1...6	Montant paye mensuellement (NT$)	Continue
DEFAULT	1 = Defaut, 0 = Non-defaut (cible)	Binaire

Le dataset presente un desequilibre notable : 77.9% de non-defauts contre 22.1% de defauts, soit un ratio d'environ 1:3.5. Ce desequilibre rend l'accuracy seule peu informative : un modele naif predisant systematiquement la classe majoritaire atteindrait 77.9% d'accuracy sans detecter aucun defaut.

3. Analyse exploratoire

L'analyse exploratoire (notebook EDA.ipynb) a revele plusieurs elements structurants pour la modelisation.

3.1 Distribution de la cible et desequilibre

Sur 30 000 observations, on compte 23 364 non-defauts et 6 636 defauts. Ce desequilibre impose l'utilisation de techniques adaptees : class_weight='balanced' pour les modeles scikit-learn, scale_pos_weight pour XGBoost, et la Focal Loss pour le reseau de neurones.

3.2 Variables les plus discriminantes

Les statuts de paiement (PAY_0 a PAY_6) constituent de loin les meilleurs predicteurs. PAY_0, le statut le plus recent, presente la correlation la plus forte avec la cible. Un client ayant accumule 2 mois ou plus de retard affiche un taux de defaut superieur a 60%. Ce constat est coherent avec la pratique bancaire : l'historique de paiement recent est le premier indicateur du scoring de credit.

La limite de credit (LIMIT_BAL) est egalement discriminante : les clients avec une faible limite font davantage defaut, ce qui reflete a la fois un profil de risque plus eleve et une capacite d'endettement limitee.

3.3 Anomalies detectees

L'exploration a identifie des valeurs non documentees : EDUCATION contient les valeurs 0, 5, 6 (345 observations) et MARRIAGE contient la valeur 0 (54 observations). Ces codes n'apparaissent pas dans la documentation officielle du dataset. Par ailleurs, 36 doublons stricts ont ete identifies. Ces anomalies ont ete corrigees dans l'etape de pretraitement.

3.4 Multicolinearite

Les variables BILL_AMT1 a BILL_AMT6 presentent des correlations mutuelles tres elevees ($r > 0.9$), ce qui est logique puisqu'il s'agit des factures successives d'un meme client. Cette multicolinearite justifie le feature engineering visant a synthetiser ces variables en indicateurs agrege (taux d'utilisation, tendance).

4. Pretraitement et feature engineering

4.1 Nettoyage des donnees

Les corrections suivantes ont ete appliquees. Les valeurs 0, 5, 6 d'EDUCATION ont ete regroupees dans la categorie 'Autre' (4), ce qui preserve l'information sans supprimer d'observations. La valeur 0 de MARRIAGE a ete regroupee en 'Autre' (3). Les statuts de paiement inferieurs a -1 (indifferencies dans la documentation) ont ete uniformises a -1. Les 36 doublons ont ete retires, portant le dataset a 29 964 observations.

4.2 Feature engineering

Sept nouvelles variables ont ete creees a partir de la connaissance du domaine bancaire. L'objectif est de capturer des signaux de risque que les variables brutes ne reflètent pas directement.

Variable	Formule	Justification financiere
taux_utilisation	Facture moy. / LIMIT_BAL	Un taux > 80% signale un client a risque (scoring FICO)
nb_mois_retard	Nb de PAY_i > 0	Historique = meilleur predicteur en scoring bancaire
retard_max	max(PAY_0, ..., PAY_6)	Gravite maximale du retard
jamais_en_retard	1 si nb_mois_retard = 0	Client sans incident = fiable
ratio_paiement	Total paye / Total facture	Capacite de remboursement
tendance_factures	Pente lineaire BILL_AMT	Factures croissantes = risque
score_risque	Combinaison ponderee	Score composite (type FICO)

Apres feature engineering, le nombre de colonnes passe de 24 a 31. L'ajout de l'encodage One-Hot (drop_first=True) pour SEX, EDUCATION et MARRIAGE porte le total a 33 features.

4.3 Normalisation et separation

Les donnees ont ete separees en trois jeux avec stratification : Train (20 986 observations, 70%), Validation (4 483, 15%) et Test (4 495, 15%). Le taux de defaut est maintenu a 22.1% dans chaque partition grace a la stratification. Le StandardScaler a ete fit exclusivement sur le Train puis applique aux deux autres partitions, garantissant l'absence de data leakage. Ce point est critique : normaliser sur l'ensemble complet reviendrait a laisser de l'information du Test influencer la transformation, biaisant l'evaluation.

5. Methodologie de validation

5.1 Stratified 5-Fold Cross-Validation

Tous les modeles ont ete evalues par Stratified 5-Fold CV. La stratification est imperative compte tenu du desequilibre : sans elle, certains folds pourraient contenir tres peu de defauts, rendant l'estimation de performance instable. Le score retenu pour la CV est l'AUC-ROC, metrique independante du seuil de classification.

5.2 Optimisation par Optuna (TPE)

Optuna a ete utilise pour l'optimisation des hyperparametres. Contrairement a GridSearch (exhaustif mais exponentiel en complexite) ou RandomSearch (rapide mais non guide), Optuna utilise l'algorithme Tree-structured Parzen Estimator (TPE) qui modelise la distribution des bons et mauvais hyperparametres pour orienter l'exploration. Chaque configuration a ete evaluee par 5-Fold CV stratifiee pour eviter l'overfitting sur un split unique.

Modele	Nb trials Optuna	Nb hyperparametres explores
Logistic Regression	25	2 (C, penalty)
Random Forest	25	4 (n_estimators, max_depth, ...)
XGBoost	30	8 (lr, depth, subsample, reg, ...)
LightGBM	30	9 (lr, num_leaves, reg, ...)
Neural Network	15	8 (architecture, dropout, lr, alpha, gamma)

5.3 Choix des metriques

L'accuracy seule est trompeuse ici (77.9% en predisant toujours 'non-defaut'). Les metriques retenues sont : **AUC-ROC** pour la capacite discriminante globale (independante du seuil) ; **F1-Score** comme compromis entre precision et recall ; **Precision**, qui mesure la proportion de vrais defauts parmi les alertes ; et **Recall**, qui mesure la proportion de defauts effectivement detectes. En gestion du risque, le recall est souvent prioritaire car un defaut non detecte (faux negatif) coute davantage qu'une alerte injustifiee (faux positif).

5.4 Integrite des donnees

Trois mesures garantissent l'absence de data leakage : (1) le scaler est fit uniquement sur le Train ; (2) le feature engineering n'utilise que des variables individuelles (aucune statistique globale) ; (3) le jeu de Test n'est utilise qu'une seule fois, lors de l'evaluation finale, apres toute optimisation.

6. Resultats - Approche classique

6.1 Baseline (parametres par defaut)

Avant optimisation, les modeles ont ete evalues avec leurs parametres par defaut (et class_weight='balanced' pour gerer le desequilibre) :

Modele	AUC-ROC CV	Ecart-type
Logistic Regression	0.7626	0.0114
Random Forest	0.7673	0.0103
XGBoost	0.7475	0.0088
LightGBM	0.7738	0.0111

A ce stade, LightGBM domine legerement. On note que XGBoost sans tuning est le moins performant, ce qui illustre sa sensibilite aux hyperparametres par defaut. La Logistic Regression, malgre sa simplicite, offre une baseline honorable, ce qui suggere une structure partiellement lineaire dans les donnees.

6.2 Apres optimisation Optuna

L'optimisation ameliore tous les modeles, avec un gain particulierement marque pour XGBoost (+4 points d'AUC en CV) qui passe de dernier a premier :

Modele	AUC CV avant	AUC CV apres	Gain
Logistic Regression	0.7626	0.7628	+0.0002
Random Forest	0.7673	0.7855	+0.0182
XGBoost	0.7475	0.7879	+0.0404
LightGBM	0.7738	0.7868	+0.0130

Le gain negligeable de la Logistic Regression confirme que son espace d'hyperparametres est restreint (C et penalty), avec peu de marge d'amelioration. Les modeles d'ensemble (RF, XGBoost, LightGBM) beneficient davantage du tuning grace a leur plus grand nombre de degres de liberte.

6.3 Evaluation finale sur le Test set

Modele	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Log. Regression	0.745	0.443	0.599	0.509	0.752
Random Forest	0.773	0.489	0.574	0.528	0.771
XGBoost	0.775	0.493	0.571	0.529	0.776
LightGBM	0.760	0.467	0.609	0.529	0.773

XGBoost obtient le meilleur AUC-ROC (0.776) et le meilleur F1-Score (0.529). **LightGBM** presente le meilleur recall (0.609), ce qui le rend attractif si la priorite est de detecter un maximum de defauts. La **Logistic Regression** offre le meilleur recall parmi les modeles simples (0.599), confirmant que le class_weight='balanced' oriente le modele vers la detection des positifs.

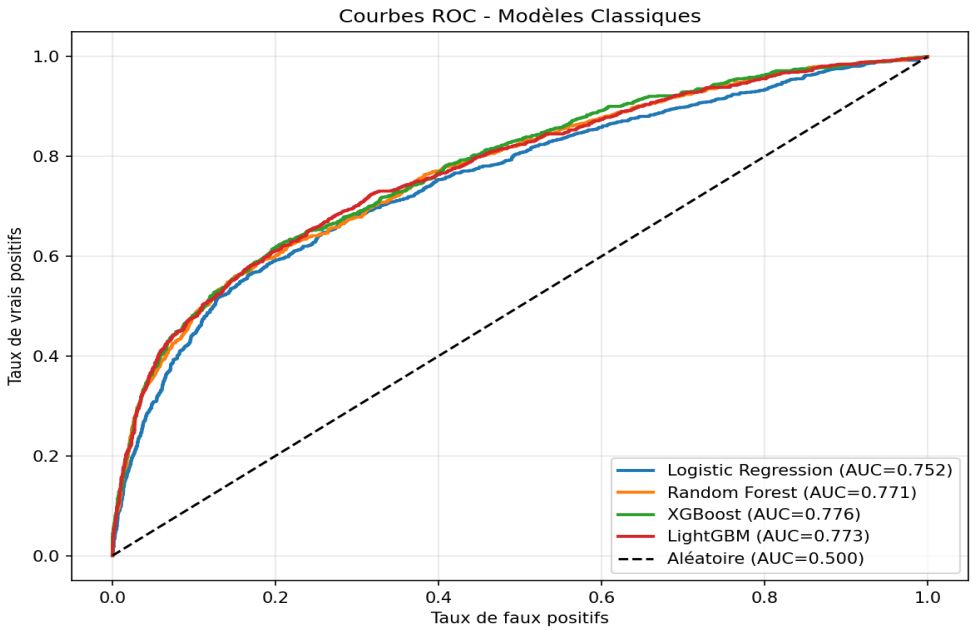

Figure 1 - Courbes ROC des modeles classiques sur le jeu de Test

Les courbes ROC sont proches, ce qui indique que les quatre modeles ont une capacite discriminante comparable. L'ecart se creuse legerement dans la zone 0.1-0.3 du taux de faux positifs, la ou la decision est la plus pertinente en pratique bancaire.

7. Resultats - Deep learning et Focal Loss

7.1 Architecture retenue

Optuna a selectionne une architecture a **2 couches cachees** (256 et 32 neurones), ce qui est plus compact que l'architecture initiale a 4 couches. Ce resultat est coherent avec la taille du dataset (30 000 observations) : un reseau trop profond risque de surapprendre sur si peu de donnees tabulaires.

Composant	Valeur
Couches cachees	[256, 32]
Dropout	0.204
Learning rate	3.7 x 10-4
Batch size	128
Focal Loss alpha	0.790
Focal Loss gamma	1.375
Optimiseur	Adam (weight_decay = 10-4)
Early stopping	Patience = 20 epochs
Scheduler	ReduceLROnPlateau (patience=5, factor=0.5)
Skip Connection	Couche 1 vers Couche 2

7.2 Analyse de l'entrainement

L'entrainement s'est arrete a l'epoch 44 par early stopping (patience=20). La loss finale est de 0.0705 (train) et 0.0745 (validation), soit un ecart de seulement 0.004, ce qui confirme l'absence de surapprentissage significatif. Le dropout a 20% et le weight_decay ont joue leur role de regularisation.

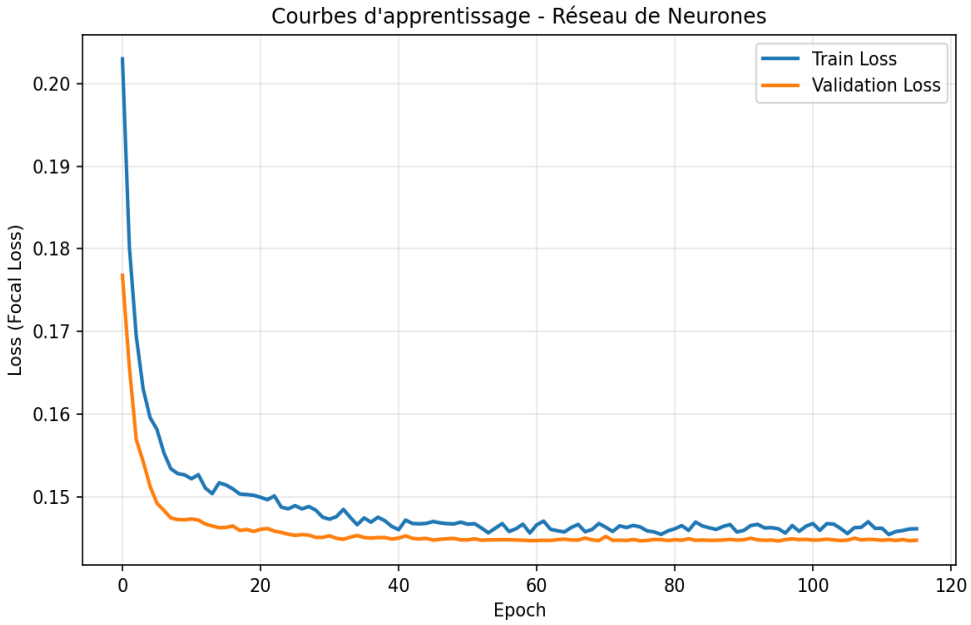

Figure 2 - Courbes d'apprentissage du reseau de neurones (Focal Loss)

Les courbes montrent une convergence rapide (environ 20 epochs) suivie d'un plateau. La validation loss est legerement inferieure a la train loss, ce qui peut s'expliquer par le dropout actif uniquement en mode train.

7.3 Evaluation sur le Test set

Metrique	Valeur
Accuracy	0.740
Precision	0.439
Recall	0.632
F1-Score	0.518
AUC-ROC	0.771
AUC-ROC CV (5-Fold)	0.778 (+/- 0.007)

Le reseau de neurones atteint un **recall de 0.632**, le plus eleve de tous les modeles. Cela signifie qu'il detecte 63.2% des defauts reels, contre 57.1% pour XGBoost. En contrepartie, sa precision est plus faible (0.439 vs 0.493), generant davantage de fausses alertes. La cross-validation 5-fold confirme la stabilite du modele (ecart-type de 0.007).

8. Composante personnalisee : Focal Loss

La Focal Loss (Lin et al., 2017) constitue la composante personnalisee (custom implementation) de ce projet. Elle a ete implementee en PyTorch dans le fichier entrainement_deep.py (classe FocalLoss).

8.1 Motivation

Avec la Binary Cross-Entropy standard, tous les exemples contribuent egalement au gradient. Dans un dataset desequilibre (78% de non-defauts), les exemples 'faciles' (non-defauts bien classifies) dominent le gradient et empechent le modele de se concentrer sur les exemples difficiles (les defauts). La Focal Loss resout ce probleme en reduisant dynamiquement le poids des exemples faciles.

8.2 Formulation mathematique

$$FL(p_t) = -alpha_t \cdot (1 - p_t)^{gamma} \cdot \log(p_t)$$

Ou p_t est la probabilite predite pour la vraie classe. Le parametre **alpha** controle le poids relatif des classes (alpha=0.79 donne plus d'importance aux defauts). Le parametre **gamma** (= 1.375 ici) module l'attention : quand gamma > 0, un exemple bien classifie (p_t proche de 1) voit sa contribution a la loss fortement reduite par le facteur $(1 - p_t)^{gamma}$. A gamma = 0, on retrouve la Cross-Entropy ponderee classique.

8.3 Details d'implementation

L'implementation est compatible avec l'autograd de PyTorch (calcul automatique des gradients). Un clamp numerique (min=10^{-7}) previent les instabilites dues a log(0). Les parametres alpha et gamma sont optimises conjointement avec l'architecture du reseau par Optuna, plutot que fixes arbitrairement.

8.4 Impact observe

La Focal Loss a permis d'obtenir le meilleur recall (0.632) parmi tous les modeles. En orientant l'apprentissage vers les exemples difficiles (les defauts), elle compense efficacement le desequilibre. Le compromis est une precision plus faible, ce qui est attendu et acceptable dans un contexte de gestion du risque ou la detection des defauts prime.

9. Comparaison et interpretation

9.1 Tableau comparatif final

Modele	Accuracy	Precision	Recall	F1	AUC-ROC
Logistic Regression	0.745	0.443	0.599	0.509	0.752
Random Forest	0.773	0.489	0.574	0.528	0.771
XGBoost	0.775	0.493	0.571	0.529	0.776
LightGBM	0.760	0.467	0.609	0.529	0.773
Neural Net (Focal)	0.740	0.439	0.632	0.518	0.771

En vert : meilleure valeur par metrique.

9.2 Interpretation

XGBoost est le meilleur modele en termes d'AUC-ROC (0.776) et de F1-Score (0.529). Ce resultat confirme la superiorite frequemment observee du gradient boosting sur les donnees tabulaires. Le **reseau de neurones avec Focal Loss** se distingue par le meilleur recall (0.632), soit 6 points de plus que le second (LightGBM, 0.609). En contexte bancaire, si l'objectif principal est de minimiser les defauts non detectes, le reseau de neurones est le meilleur choix.

L'ecart entre les modeles reste modere (AUC entre 0.752 et 0.776), ce qui suggere que la performance est en grande partie limitee par le signal contenu dans les donnees, et non par la complexite du modele. Les features issues du feature engineering (statuts de paiement, taux d'utilisation) captent l'essentiel de l'information.

9.3 Analyse par cas d'usage

Objectif	Modele recommande	Raison
Meilleure AUC globale	XGBoost	AUC = 0.776, F1 = 0.529
Detecter max. de defauts	Neural Net (Focal)	Recall = 0.632 (meilleur)
Moins de fausses alertes	XGBoost	Precision = 0.493 (meilleure)
Interpretabilite	Logistic Regression	Coefficients interpretables
Rapidite d'entrainement	LightGBM	Plus rapide que XGBoost

10. Analyse critique et limites

10.1 Limites du dataset

Le dataset date de 2005 et concerne uniquement des clients taiwanais. Les comportements financiers, les reglementations et les conditions economiques ont considerablement evolue depuis. La generalisation a d'autres populations ou periodes n'est pas garantie. De plus, 30 000 observations restent relativement modestes pour le deep learning, ce qui explique en partie pourquoi le reseau de neurones ne surpasse pas nettement les methodes classiques en AUC.

10.2 Choix du seuil de classification

Tous les resultats utilisent un seuil de 0.5, ce qui n'est pas necessairement optimal. En gestion du risque de credit, une analyse cout-benefice devrait determiner le seuil : si le cout d'un defaut non detecte est 5 fois superieur a celui d'une fausse alerte, un seuil de 0.3 serait plus pertinent, augmentant le recall au prix de la precision. L'AUC-ROC capture cette notion en evaluant la performance a tous les seuils.

10.3 Risques methodologiques

Bien que des precautions aient ete prises contre le data leakage, certains aspects meritent vigilance. L'optimisation Optuna sur la validation peut induire un leger surapprentissage aux specificites de cette partition. Idealement, une nested cross-validation (CV imbriquee) offrirait une estimation plus robuste, mais au prix d'un cout de calcul significativement plus eleve.

10.4 Ameliorations envisageables

Plusieurs pistes pourraient ameliorer les resultats : (1) le sur-echantillonnage par SMOTE pour equilibrer artificiellement les classes ; (2) le stacking pour combiner les predictions des differents modeles ; (3) la calibration des probabilites (Platt scaling) pour des predictions plus fiables ; (4) des features temporelles plus avancees (moyennes mobiles, volatilite des paiements) ; (5) un seuil optimise par analyse cout-benefice specifique au portefeuille.

11. Conclusion

Ce projet a compare rigoureusement cinq approches de classification pour la prediction du defaut de paiement, en respectant une demarche scientifique stricte : separation Train/Validation/Test stratifiee, cross-validation 5-fold, optimisation par Optuna, et prevention systematique du data leakage.

Les resultats confirment la superiorite du gradient boosting (XGBoost) sur les donnees tabulaires en termes d'AUC-ROC globale (0.776). Cependant, le reseau de neurones equipe de la Focal Loss personnalisee offre un apport specifique et mesurable : le meilleur recall (0.632), soit une capacite superieure a detecter les defauts reels. Dans un contexte de gestion du risque ou le cout d'un defaut non anticipe est eleve, cette approche merite consideration.

La composante personnalisee (Focal Loss) illustre l'importance d'adapter la fonction de cout au probleme plutot que d'appliquer les parametres par defaut. Le fait que ses parametres (alpha, gamma) soient optimises par Optuna, et non fixes arbitrairement, renforce la rigueur de la demarche.

Enfin, ce projet illustre que la performance maximale ne se reduit pas a une seule metrique. Le choix du 'meilleur' modele depend de l'objectif metier : minimiser les pertes, optimiser le capital reglementaire, ou reduire les frictions clients. La modelisation n'est qu'un outil ; c'est l'analyse critique qui lui donne sa valeur.

References : Yeh & Lien (2009), UCI ML Repository. | Lin et al. (2017), Focal Loss for Dense Object Detection. | Chen & Guestrin (2016), XGBoost. | Ke et al. (2017), LightGBM.